

PRML 作业 4: Transformer 模块消融与改进实验

Wang Hongyu (22371297)
2026 Spring

摘要

本文阅读并复现《Attention Is All You Need》的核心结构思想，并在一个可控的指针检索任务上进行消融实验。输入序列第一个 token 表示要读取的位置，后续 token 为随机数字，模型需要输出被指向位置的数字。该任务规模小、可重复，但必须同时利用位置信息、内容寻址和跨距离信息传递，因此适合验证 Transformer 关键模块的必要性。实验中最佳模型为 Transformer-learned-pos，测试准确率为 1.000。

1. 论文核心结构理解

Transformer 将序列建模的主体从循环或卷积替换为多头自注意力。每个编码层包含多头自注意力、逐位置前馈网络、残差连接和层归一化；由于结构本身不含循环和卷积，输入嵌入必须加入位置编码。自注意力把每个位置到其它位置的路径长度压缩为常数级，有利于学习长距离依赖，并且训练时可并行计算。Q、K、V 的分工是：Q 表示当前位置要寻找什么，K 表示每个候选位置如何被匹配，V 表示被汇聚的信息内容。

2. 实验任务与设置

合成数据长度为 9：第 0 个 token 是查询 token，取值 10 到 17，分别表示读取后面 8 个 value token 中的某一位；第 1 到 8 个 token 是 0 到 9 的随机数字；分类标签为查询所指向位置的数字。所有模型使用相同训练步数、批大小和优化器，以保证消融结果主要反映结构差异。

项目	取值
序列长度	1 query + 8 value tokens
类别数	10
训练步数	700
批大小	128
评价方式	固定随机种子的测试批平均准确率

3. 主要实验结果

模型	位置编码	KV 共享	残差	测试准确率	测试损失
Transformer-learned-pos	learned	否	standard	1.000	0.001
Adaptive-PE-transformer	adaptive_sinusoidal	否	standard	0.794	0.612
Transformer-sinusoidal	sinusoidal	否	standard	0.511	1.207
Shared-KV-attention	sinusoidal	是	standard	0.375	1.571
Positional-CNN	learned	否	standard	0.325	1.780
No-residual	sinusoidal	否	none	0.301	1.689
Transformer-simple-abs	simple_abs	否	standard	0.295	1.716
No-position-encoding	none	否	standard	0.294	1.716

表 1：各结构变体在指针检索任务上的最终测试指标。




图 1: 不同结构变体的最终准确率。




图 2: 训练过程中的验证准确率曲线。

4. 针对作业问题的分析

4.1 位置编码的核心作用

若不加入位置编码，自注意力层对 value token 的顺序近似不敏感，只能看到一组数字的多重集合，无法知道查询 token 指向的是第几个位置。因此在本任务中 No-position-encoding 明显退化。简单绝对位置编码能够提供位置索引，学习型位置编码和正弦位置编码均可取得较好结果；正弦位置编码的优势在于不增加位置表参数，并具备潜在的长度外推能力。




图 3：位置编码形式对指针检索准确率的影响。

4.2 Q、K、V 的必要性

在标准注意力中，Q-K 点积负责计算匹配权重，V 负责提供被加权汇聚的内容。若令 K 与 V 共享同一投影，模型必须用同一表示同时承担“可匹配的位置线索”和“要输出的数字内容”，表达空间受到约束。实验中的 Shared-KV-attention 仍可学习，但收敛和最终准确率通常低于标准 Transformer，说明 K/V 解耦能降低优化难度。

4.3 不采用 ResNet 残差结构的影响

去掉残差后，每一层只能保留子层变换后的表示，原始 token 嵌入和位置线索更容易在深层传播中被覆盖；梯度也必须穿过所有非线性子层，训练更不稳定。No-residual 的准确率下降表明：残差连接不仅是深层网络训练技巧，也是保持 token 身份、位置信息和注意力更新可叠加的重要结构。

4.4 位置编码 + CNN 与自注意力 Transformer 对比

CNN 在加入位置编码后能利用局部卷积逐步传播信息，但第 0 个查询 token 要读取任意远处位置，需要多层卷积才能建立远距离路径；自注意力则一层即可让查询位置访问全部 value token。实验中 Positional-CNN 明显弱于 Transformer，验证了论文中关于最大路径长度和长距离依赖学习难度的讨论。




图 4: 标准 Transformer 第一层平均注意力示例。颜色越亮表示注意力权重越高。

4.5 独立改进：自适应正弦位置编码

本文提出一个小型改进：保留原论文的正弦位置编码形式，但加入可学习的逐维缩放向量，即 $x + \alpha * PE(pos)$ ，其中 α 由训练数据学习。动机是固定正弦信号在短序列小模型中可能相对 token 嵌入偏弱，模型需要自动调节位置通道的幅度。实验中 Adaptive-PE-transformer 明显优于固定正弦位置编码，说明该改进在有限长度检索任务上可行；代价仅为 d_{model} 个额外参数，但是否保持原正弦编码的长度外推性质仍需进一步实验。

5. 结论

实验表明：位置编码是无循环、无卷积 Transformer 理解序列顺序的入口；Q/K/V 解耦让匹配与信息读取分别建模；残差连接显著改善信息和梯度传播；自注意力相比局部 CNN 更适合本实验中的动态长距离检索。自适应正弦位置编码作为本文提出的独立改进，在小规模任务上验证了可行性，但还需要在真实语言任务和更长序列上检验稳定性。

参考文献

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin. Attention Is All You Need. arXiv:1706.03762, 2017.
- [2] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. Deep Residual Learning for Image Recognition. CVPR, 2016.
- [3] Jimmy Lei Ba, Jamie Ryan Kiros, Geoffrey E. Hinton. Layer Normalization. arXiv:1607.06450, 2016.